

Introduction

Dans ce rapport, je présente mon implémentation des algorithmes Q-Learning (avec et sans Epsilon Scheduling) et SARSA pour résoudre le jeu Taxi-v3 de OpenAI Gym. L'objectif est d'implémenter un agent capable de prendre un passager sur une case spécifique et de le déposer à une destination spécifique en un minimum de temps.

Choix d'Implémentation

Grid Search

La méthode de Grid Search a été utilisée pour optimiser les hyperparamètres des algorithmes. Les paramètres testés incluent :

- `learning_rate` : [0.1, 0.3, 0.5, 0.7]
- `epsilon` : [0.01, 0.05, 0.1, 0.25]
- `gamma` : [0.9, 0.95, 0.99]

Algorithmes

Q-Learning, Q-Learning avec Epsilon Scheduling, SARSA

Analyse des Résultats (Graphique fourni en page 2)

- Le Q-Learning atteint une récompense moyenne finale de 6.93 en 0.19 secondes, ce qui est compétitif en termes de performance et de temps.
- Le Q-Learning avec Epsilon Scheduling a une récompense moyenne finale de 4.34, ce qui est inférieur aux autres algorithmes, mais il converge rapidement au début.
- SARSA obtient la récompense moyenne finale la plus élevée de 7.22, mais prend un peu plus de temps (0.27 secondes).

Algorithme	Paramètres Optimaux	Temps (s)	Récompense Moyenne Finale
Q-Learning	<code>learning_rate=0.5</code> , <code>epsilon=0.01</code> , <code>gamma=0.99</code>	0.19	6.93
Q-Learning Epsilon Scheduling	<code>learning_rate=0.7</code> , <code>epsilon=0.1</code> , <code>gamma=0.99</code>	0.17	4.34
SARSA	<code>learning_rate=0.3</code> , <code>epsilon=0.01</code> , <code>gamma=0.99</code>	0.27	7.22

Table 1: Paramètres optimaux, temps d'entraînement et récompenses moyennes finales pour chaque algorithme.

Conclusion

Les trois algorithmes sont capables d'apprendre une politique efficace pour le jeu Taxi-v3, on peut notamment le vérifier sur les vidéos de chaque algorithme. Le choix entre eux dépendra des contraintes spécifiques du problème, comme le temps de calcul disponible, la nécessité d'une convergence rapide, ou encore la nécessité de minimiser la quantité de risque pris (besoin de prudence). Dans ce dernier cas, on préférera un algorithme on-policy tel que SARSA.




Figure 1: Courbes d'apprentissage pour Q-Learning, Q-Learning avec Epsilon Scheduling, et SARSA.